

Portabilité inter-appareils des attaques par canal auxiliaire

mise en évidence du verrou et adaptation de domaine

Pierre-Louis Tissot

ESILV — École Supérieure d'Ingénieurs Léonard de Vinci
Majeure Objets connectés et cybersécurité — Stage de fin d'études, Airbus Protect
Email : pierre-louis.tissot-favre@edu.devinci.fr

Résumé—Les attaques par canal auxiliaire profilées par apprentissage profond récupèrent efficacement une clé AES lorsque le modèle est entraîné et évalué sur le même dispositif. En conditions réalistes, l'attaquant profile sur un appareil et attaque un appareil distinct : la performance s'effondre. Ce travail établit d'abord une chaîne d'attaque de référence, validée sur la base ASCAD où un perceptron multicouche récupère la clé en 614 traces. Il quantifie ensuite l'écart de portabilité sur la base multi-appareils AES_PT : sur un même appareil la clé sort en 312 traces, tandis qu'un transfert direct vers trois autres appareils ne la récupère jamais, et une renormalisation par appareil ne suffit pas à combler cet écart. Nous évaluons enfin une méthode d'adaptation de domaine adversariale (DANN). Les représentations apprises s'alignent effectivement entre appareils — d'autant mieux que ceux-ci sont distants — mais cet alignement ne se traduit pas en gain d'attaque fiable : moyenné sur huit octets de clé, l'avantage du DANN est indiscernable du bruit, la variance inter-octets dominant l'effet, et aucune configuration ne récupère la clé. Le résultat central est ce découplage entre alignement des distributions et succès de l'attaque.

Index Terms—attaque par canal auxiliaire, analyse de consommation, apprentissage profond, adaptation de domaine, DANN, portabilité, AES, guessing entropy.

I. INTRODUCTION

Un circuit qui exécute un algorithme cryptographique laisse fuir de l'information par ses canaux physiques : consommation électrique, rayonnement électromagnétique, temps de calcul. Les attaques par canal auxiliaire (SCA) exploitent ces fuites pour retrouver une clé secrète sans s'attaquer mathématiquement au chiffrement. Dans le cadre *profilé*, l'attaquant dispose d'un dispositif de référence qu'il maîtrise : il y enregistre un grand nombre de traces étiquetées pour construire un modèle de la fuite, qu'il applique ensuite au dispositif cible. Depuis l'introduction de la base ASCAD, les réseaux de neurones profonds se sont imposés comme l'outil dominant de cette phase de profilage, surpassant les attaques par gabarits classiques.

Ces succès sont presque toujours mesurés en conditions idéales : profilage et attaque sur le *même* appareil. Or un évaluateur de sécurité, ou un attaquant réel, ne possède que rarement l'exemplaire exact qu'il vise. Deux puces nominale-

ment identiques diffèrent par la variabilité de fabrication, la chaîne d'acquisition et le bruit. Le modèle, devenu spécialiste de la signature physique de son appareil d'origine, se transfère mal : c'est le problème de *portabilité*, qui conditionne la pertinence réelle de toute attaque profilée.

Le modèle d'attaquant considéré est le suivant. L'attaquant possède un dispositif de profilage qu'il maîtrise pleinement (clés connues, nombre illimité de traces étiquetées). Il vise un second dispositif, du même modèle mais physiquement distinct, dont il peut enregistrer les traces de consommation mais dont il ignore la clé. Son objectif est de retrouver cette clé. Ce scénario, dit inter-appareils, est celui d'un laboratoire d'évaluation ou d'un attaquant réaliste qui ne dispose jamais de l'exemplaire exact visé ; c'est aussi celui où la portabilité devient critique.

Ce travail pose la question suivante : *dans quelle mesure une méthode d'adaptation de domaine adversariale (DANN) permet-elle de restaurer la portabilité inter-appareils d'une attaque profilée, comparée à un transfert direct et à une renormalisation par appareil ?* Notre hypothèse initiale était qu'en rendant les représentations internes indiscernables entre l'appareil de profilage et l'appareil cible, l'adaptation alignerait leurs distributions et restaurerait une fuite exploitable.

La Section II situe ce travail dans l'état de l'art. La Section III décrit les données, la métrique et les architectures. La Section IV présente la validation de la chaîne, la mise en évidence du verrou et la mise au point de l'adaptation. La Section V analyse *quand* l'adaptation aide. La Section VI en discute la portée et les limites. La Section VII conclut sur les contributions et les perspectives.

II. ÉTAT DE L'ART

A. Contexte industriel et évaluation de sécurité

L'évaluation de la résistance d'un composant aux attaques physiques est une activité industrielle encadrée, notamment dans le cadre de la certification de produits sécurisés (cartes à puce, éléments sécurisés, microcontrôleurs). Les implémentations déploient des contre-mesures : le *masquage* booléen,

qui rend la fuite dépendante d'aléas internes, et la *désynchronisation* ou le jitter d'horloge, qui décalent temporellement la fuite. La portabilité y est un enjeu concret : un laboratoire d'évaluation ne dispose pas toujours du composant exact attaqué, et la transférabilité d'un modèle entre exemplaires conditionne le réalisme du verdict de sécurité.

B. De l'analyse de consommation classique aux gabarits

Les premières attaques par canal auxiliaire exploitent directement la dépendance statistique entre la consommation instantanée et les données manipulées. L'analyse différentielle (DPA) [7] partitionne un grand nombre de traces selon la valeur prédite d'un bit intermédiaire et compare les moyennes des deux groupes ; une différence significative révèle l'hypothèse de clé correcte. L'analyse par corrélation (CPA) [8] raffine cette idée en corrélant la consommation mesurée à un modèle de fuite, typiquement le poids de Hamming d'une valeur intermédiaire. Ces attaques ne requièrent aucun apprentissage préalable mais supposent un modèle de fuite explicite et correct. Les attaques par *gabarits* [9] introduisent la phase de profilage qui caractérise le cadre étudié ici : sur un dispositif de référence maîtrisé, on estime la distribution de la consommation (souvent supposée gaussienne) pour chaque valeur intermédiaire, puis on classe les traces de la cible par maximum de vraisemblance. L'apprentissage profond est l'héritier direct de ce cadre profilé, dont il relâche l'hypothèse de distribution paramétrique.

C. L'essor de l'apprentissage profond

La diffusion de la base ASCAD [1] a fait basculer le domaine vers l'apprentissage profond, en fournissant un jeu de référence de traces d'un AES masqué sur microcontrôleur. Un perceptron multicouche ou un réseau convolutif y apprend directement, à partir des traces brutes, à prédire la valeur intermédiaire ciblée, sans modèle de fuite explicite et avec une robustesse accrue à la désynchronisation. Des architectures compactes ont ensuite été proposées pour réduire fortement la taille des réseaux tout en cassant la clé efficacement [5], soulignant l'importance du réglage face au sur-apprentissage. Un point méthodologique structurant traverse cette littérature : la métrique pertinente n'est pas la précision de classification mais le *rang* de la clé correcte agrégé sur plusieurs traces (*guessing entropy*). Plusieurs travaux ont montré que ces deux quantités sont largement décorrélées [6] : un classifieur de précision à peine supérieure au hasard peut suffire à récupérer la clé, car l'attaque accumule un biais faible mais cohérent sur de nombreuses traces.

D. Adaptation de domaine et portabilité

Le problème de portabilité a été formalisé et instrumenté par une étude dédiée [2], qui a produit la base multi-appareils utilisée ici et mis en évidence l'effondrement du transfert direct entre exemplaires. Pour y remédier, l'adaptation de domaine cherche à apprendre des représentations *invariantes au domaine* — ici, à l'appareil. Deux familles coexistent. Les méthodes *adversariales*, dont le DANN [3] est le représentant

canonique, opposent au réseau un discriminateur de domaine que l'on cherche à tromper, via une couche d'inversion de gradient. Les méthodes *statistiques*, comme CORAL [10] ou l'alignement par maximum mean discrepancy (MMD), alignent directement les moments des distributions (moyenne, covariance) sans entraînement adversarial, et sont réputées plus stables. Ces approches ont été transposées à la SCA, notamment par des méthodes non supervisées d'alignement entre dispositifs [4]. Ce travail s'inscrit dans cette lignée et évalue spécifiquement le DANN sur la base AES_PT.

III. MÉTHODES ET MATÉRIELS

A. Jeux de données

Deux bases sont employées avec des rôles distincts. **ASCAD** [1] sert à valider la chaîne d'attaque sur un benchmark de référence : AES masqué, fenêtre de 700 points d'intérêt, 50 000 traces de profilage et 10 000 traces d'attaque, octet cible numéro 2. **AES_PT** [2] sert à l'étude de portabilité : elle contient les traces de quatre appareils nominalement identiques (notés D1 à D4), pour une implémentation non protégée (1 225 points) et une implémentation masquée (2 300 points), avec des campagnes à clé fixe et à clé aléatoire. L'étude se concentre sur l'implémentation non protégée.

B. Périmètre et préparation des données

La base AES_PT, d'un volume d'environ 14 Go, couvre quatre appareils, deux implémentations (non protégée et masquée) et deux types de campagne (clé fixe et clé aléatoire). Cette étude se restreint volontairement à l'implémentation *non protégée*, pour deux raisons. D'une part, elle isole le phénomène de portabilité de la difficulté supplémentaire introduite par le masquage : la fuite y est directe, ce qui garantit qu'un éventuel échec inter-appareils est imputable à la variabilité des dispositifs et non à la contre-mesure. D'autre part, elle réduit le volume manipulé à quelques giga-octets, rendant les entraînements reproductibles sur une infrastructure à accélération GPU. Concrètement, un sous-ensemble ne conservant que les traces, textes clairs et clés de l'implémentation non protégée des quatre appareils a été extrait, sans aucune modification des données elles-mêmes. Le cas masqué, présent dans la base, est réservé aux perspectives (Section VII).

C. Modèle de fuite et métrique

On cible la sortie de la première couche de substitution (S-box) du premier tour :

$$Z = \text{Sbox}(p \oplus k), \quad (1)$$

où p est l'octet de texte clair connu et k l'octet de clé recherché, soit 256 classes. La qualité d'une attaque est mesurée par la *guessing entropy*. Pour une hypothèse de clé k et N traces d'attaque (t_i, p_i) , on cumule les log-probabilités fournies par le modèle :

$$d_N(k) = \sum_{i=1}^N \log \hat{p}(Z = \text{Sbox}(p_i \oplus k) \mid t_i). \quad (2)$$

Le rang de la vraie clé k^* est le nombre d'hypothèses mieux notées,

$$\text{rang}_N = |\{k : d_N(k) > d_N(k^*)\}|, \quad (3)$$

et la guessing entropy est son espérance sur des tirages aléatoires de l'ordre des traces. Ce rang part de ≈ 128 (clé noyée) et tend vers 0 lorsque l'attaque réussit. On note « traces pour casser » le plus petit nombre de traces amenant ce rang à zéro.

D. Architectures

Trois modèles sont utilisés. Un **MLP** de référence (six couches denses de 200 neurones, sortie à 256 classes), conforme au baseline historique d'ASCAD. Un **CNN** compact (une convolution, une normalisation, un sous-échantillonnage, deux couches denses). Pour l'adaptation, un **DANN** : un tronc commun extrait des caractéristiques alimentant deux têtes, une tête de classification de Z et une tête de discrimination du domaine (appareil source contre cible), reliée au tronc par une couche d'inversion de gradient. Cette inversion pousse le tronc à produire des caractéristiques sur lesquelles le discriminateur de domaine échoue, donc indépendantes de l'appareil. Le poids λ de l'inversion suit un planning : nul pendant une phase d'échauffement, puis croissant.




FIGURE 1. Architecture du DANN : un tronc extrait des caractéristiques alimentant une tête de classification de Z et une tête de discrimination du domaine, reliée au tronc par la couche d'inversion de gradient (poids $-\lambda$).

TABLE I
HYPERPARAMÈTRES DU DANN (RÉGIME RETENU, $\lambda_{\max} = 0,1$).

Élément	Valeur
Tronc (extracteur)	3 couches denses, 200 neurones
Tête de classification	1 couche 200 + softmax 256
Tête de domaine	1 couche 100 + softmax 2
Optimiseur	Adam, taux 10^{-3}
Taille de lot	128
Époques	60 (échauffement : 30)
Traces de profilage	40 000

E. Protocole

Les traces sont standardisées (moyenne nulle, variance unité par point), l'ajustement étant fait sur le profilage puis appliqué à l'attaque. Le profilage utilise les campagnes à clé aléatoire, l'attaque la campagne à clé fixe, dont la valeur est retrouvée comme clé majoritaire. La guessing entropy est moyennée sur plusieurs tirages aléatoires de l'ordre des traces d'attaque.

IV. RÉSULTATS

A. Validation de la chaîne sur ASCAD

Avant tout entraînement, la métrique elle-même est validée (Fig. 2) : un oracle parfait fait chuter le rang de la vraie clé à zéro en quelques traces, tandis qu'un classifieur aléatoire le maintient autour de 128. La chaîne de mesure est donc correcte.




FIGURE 2. Validation de la métrique : un oracle parfait fait chuter le rang à 0, un classifieur aléatoire le maintient autour de 128.

Sur ASCAD, le MLP de référence récupère la clé en **614 traces** (Fig. 3) : la guessing entropy plonge de ≈ 110 vers 0 et s'y stabilise. Le CNN compact, sous le réglage employé, ne casse pas la clé : son rang reste élevé. Ce dernier point est attribué à un sous-réglage (noyau de convolution trop étroit, nombre d'époques insuffisant) plutôt qu'à une limite de fond ; le succès du MLP suffit à valider la chaîne et la métrique.




FIGURE 3. Guessing entropy sur ASCAD : le MLP casse la clé, le CNN (sous-réglé) échoue.

Un constat mérite d'être souligné car il structure toute la discussion : la précision de classification du MLP est d'environ 1,9 %, celle du CNN d'environ 0,5 %, à comparer au hasard pur de $1/256 \approx 0,39\%$. Le MLP n'est donc qu'à environ cinq fois le hasard, et pourtant il récupère la clé entière. Cela illustre concrètement la décorrélation entre précision et succès

d'attaque : la guessing entropy n'évalue jamais une trace isolée mais l'*accumulation* d'un faible biais correct sur des centaines de traces.

B. Mise en évidence du verrou de portabilité

Sur AES_PT (non protégé), un modèle profilé sur D1 et évalué sur D1 récupère la clé en **312 traces** : l'attaque intra-appareil fonctionne. Appliqué directement à D2, D3 et D4, ce même modèle ne récupère *jamais* la clé : les courbes de guessing entropy restent élevées sans tendance à décroître (Fig. 4). Le passage de 312 traces à un échec total constitue la mise en évidence quantifiée du verrou.




FIGURE 4. Guessing entropy : attaque intra-appareil (D1→D1) contre transfert direct inter-appareils (D1→D2/D3/D4).

C. Renormalisation par appareil : un palier, mais pas la clé

La première correction, peu coûteuse, consiste à renormaliser les traces de la cible avec ses *propres* statistiques (l'attaquant possède les traces, sans en connaître les clés) plutôt qu'avec celles de la source. Elle aligne les distributions marginales des deux appareils sans rien apprendre de plus. Son effet est net mais partiel : sur D2, le rang minimal du modèle profilé sur D1 passe d'environ 110 pour le transfert brut à un plancher d'environ 28 une fois la cible renormalisée (Fig. 5). La fuite redevient donc partiellement exploitable, mais la clé n'est jamais récupérée, y compris en élargissant la fenêtre d'attaque à 5000 traces. Ce transfert renormalisé constitue la *référence* (« source-seul ») à laquelle l'adaptation de domaine est comparée dans la suite, à architecture et entraînement identiques.

D. Mise au point du DANN

L'entraînement adversarial étant réputé sensible au poids λ de la couche d'inversion de gradient, son réglage a été conduit de façon incrémentale sur le couple D1→D2, à architecture identique à celle du transfert renormalisé de référence. Deux régimes ont été évalués successivement.

Régime à adversaire fort ($\lambda_{\max} = 0,5$). Un entraînement long y dégrade le résultat par rapport à un entraînement court : une fois λ porté à son maximum, la tête de domaine n'efface

pas seulement la signature de l'appareil mais aussi une part de l'information de fuite.

Régime à adversaire doux ($\lambda_{\max} = 0,1$, échauffement prolongé). Ce régime, conçu pour laisser le tronc apprendre la fuite avant que le discriminateur ne pèse, est retenu pour la suite. Sur un octet donné, le transfert renormalisé de référence se stabilise à un rang d'environ 28, tandis que le DANN plafonne plus haut, à un rang d'environ 44 (Fig. 5) ; aucune des deux approches ne récupère la clé. Cette comparaison sur un octet unique est généralisée et nuancée en Section V.




FIGURE 5. Portabilité D1→D2 ($\lambda_{\max} = 0,1$, jusqu'à 5000 traces) : le transfert renormalisé (source-seul) atteint un plancher de rang ≈ 28 , le DANN reste plus haut (≈ 44). Aucun ne récupère la clé.

V. ANALYSE : QUAND L'ADAPTATION AIDE-T-ELLE ?

Le constat précédent appelle une question : l'échec du DANN est-il systématique, ou l'adaptation aide-t-elle dans certaines conditions ? Nous formulons l'hypothèse que *le bénéfice de l'adaptation croît avec l'ampleur du décalage entre appareils*, et la testons par trois analyses : la relation entre difficulté du transfert et gain, le mécanisme interne de l'alignement, et la robustesse du gain sur plusieurs octets.

A. Difficulté du transfert et gain de l'adaptation

Pour quantifier le décalage entre D1 et chaque cible, un classifieur binaire entraîné à distinguer leurs traces s'est révélé inadapté : il sépare D1 de tout autre appareil avec une exactitude de 1,0, saturant la mesure. Nous retenons donc comme indicateur de décalage la *difficulté du transfert direct* elle-même, c'est-à-dire le rang minimal atteint par le transfert renormalisé : plus il est élevé, plus l'appareil cible est « loin ». Sur un octet donné, le gain du DANN (rang du transfert moins rang du DANN) tend à croître avec cette difficulté (Fig. 6) : négligeable ou négatif sur les transferts les plus faciles, plus marqué sur le plus difficile. Cette tendance demeure toutefois illustrative — trois cibles, un octet — et est mise à l'épreuve en Section V-C.

B. Mécanisme : l'adaptation aligne effectivement les domaines

Pour comprendre l'effet du DANN, on suit la précision du discriminateur de domaine au cours de l'entraînement (Fig. 7).




FIGURE 6. Gain du DANN en fonction de la difficulté du transfert direct (rang source-seul). La tendance, croissante, repose sur un octet unique et trois cibles.

Elle part d’une valeur élevée — la plus haute pour D4, confirmant qu’il est le plus distinguable de D1 donc le plus distant — puis chute vers 0,5 à mesure que λ augmente : le tronc apprend des représentations sur lesquelles l’appareil n’est plus identifiable. La projection des représentations internes (Fig. 8) confirme visuellement cet alignement : les nuages de D1 et D4, décalés sans adaptation, se superposent nettement après DANN. L’adaptation accomplit donc bien ce pour quoi elle est conçue : aligner les distributions des deux appareils.




FIGURE 7. Précision du discriminateur de domaine au fil des époques. Elle part le plus haut pour D4 (appareil le plus distant) puis chute vers 0,5 : les appareils deviennent indiscernables dans l’espace des représentations.

C. Robustesse : un gain noyé dans la variance inter-octets

L’alignement réussi se traduit-il en gain d’attaque fiable ? Pour le déterminer sans biais lié à la fuite propre à chaque octet, nous mesurons le gain *apparié* octet par octet (rang du transfert moins rang du DANN sur le même octet), pour la cible facile (D2) et la cible distante (D4), sur huit octets de clé (Tab. II). Le résultat est sans appel : le gain moyen est de $-3,8 \pm 31,0$ sur D2 et de $+5,4 \pm 23,4$ sur D4. Dans les deux cas,




FIGURE 8. Projection PCA des représentations internes (D1 vs D4). Sans adaptation, les nuages sont décalés ; avec DANN, ils se superposent.

l’écart-type dépasse largement la moyenne. Le détail par octet est éloquent : sur D4, le gain atteint +50 sur certains octets mais -20 sur d’autres. L’avantage apparent observé sur un octet isolé ne survit donc pas à la moyenne : il est indiscernable du bruit.

TABLE II
GAIN DU DANN PAR OCTET (RANG SOURCE-SEUL — RANG DANN ; POSITIF = LE DANN AIDE). LA DERNIÈRE LIGNE DONNE LA MOYENNE $\pm$ L’ÉCART-TYPE.

Octet	Gain sur D2	Gain sur D4
0	+23,9	+36,1
1	+9,0	−7,4
2	−72,1	−19,2
3	−2,4	+3,7
4	+36,6	+49,8
5	−24,5	−19,7
6	−0,9	−0,1
7	+0,0	−0,1
moyenne	$-3,8 \pm 31,0$	$+5,4 \pm 23,4$

D. Synthèse

Ces trois analyses convergent vers un constat unique et nuancé : le DANN *aligne* effectivement les domaines, et d’autant mieux que l’appareil est distant ; mais cet alignement ne se *traduit pas* en gain d’attaque exploitable. Sur huit octets, son avantage s’annule, et aucune configuration ne récupère la clé. Autrement dit, *l’alignement des distributions n’implique pas le succès de l’attaque* : c’est le découplage central mis en évidence par ce travail.

VI. DISCUSSION

Le contraste central de ce travail est net : une attaque profilée par apprentissage profond récupère la clé en quelques centaines de traces sur son appareil d’origine (614 sur ASCAD, 312 en intra-appareil sur AES_PT) mais échoue à le faire dès qu’on change d’appareil. Ce verrou n’est pas un simple artefact d’échelle : la renormalisation par appareil réduit nettement le rang sur la cible (plancher ≈ 28 sur D2) mais ne récupère jamais la clé, ce qui indique que la divergence résiduelle se situe dans la structure même des représentations apprises, au-delà des statistiques marginales.

Le point le plus instructif concerne l'adaptation de domaine. Nos analyses montrent que le DANN réussit sa tâche d'alignement — la précision-domaine chute vers 0,5, les représentations des deux appareils se superposent — et que cet alignement est d'autant plus marqué que l'appareil est distant. Pourtant, ce succès ne se transmet pas à l'attaque : moyenné sur huit octets, le gain de rang est noyé dans une variance qui le dépasse, et la clé n'est jamais récupérée. Ce découplage entre alignement des distributions et exploitabilité de la fuite est, selon nous, le résultat le plus important : aligner les domaines ne garantit pas que l'information conservée soit celle qui sert l'attaque.

Plusieurs limites encadrent ces résultats. L'étude porte sur l'implémentation non protégée et sur huit octets de clé, avec une initialisation par octet ; la forte variance observée appelle, pour un travail ultérieur, une moyenne conjointe sur les octets et les graines. Le cas masqué, présent dans la base, sera par ailleurs plus difficile. Enfin, la mise au point du DANN n'a exploré qu'une partie de l'espace des hyperparamètres.

VII. CONCLUSION ET PERSPECTIVES

Ce travail a établi une chaîne d'attaque profilée validée sur ASCAD, quantifié le verrou de portabilité sur la base multi-appareils AES_PT — une attaque qui réussit en 312 traces sur son appareil d'origine échoue sur trois autres appareils — puis montré qu'une renormalisation par appareil ne suffit pas à le lever. L'évaluation de l'adaptation de domaine adversariale aboutit à un constat nuancé et rigoureusement établi : le DANN aligne effectivement les distributions des appareils, et ce d'autant mieux que la cible est distante, mais cet alignement ne produit pas de gain d'attaque robuste — sur huit octets, l'avantage est noyé dans la variance et aucune clé n'est récupérée. La contribution principale est ce découplage entre alignement des distributions et succès de l'attaque.

Les perspectives découlent directement de ces limites : une moyenne conjointe sur octets et graines pour stabiliser la mesure, la comparaison à des méthodes d'alignement non adversariales (CORAL, MMD) réputées plus stables, et le passage à l'implémentation masquée, plus représentative des cibles réelles.

RÉFÉRENCES

- [1] R. Benadjila, E. Prouff, R. Strullu, E. Cagli et C. Dumas, *Study of Deep Learning Techniques for Side-Channel Analysis and Introduction to ASCAD Database*, IACR ePrint 2018/053 ; Journal of Cryptographic Engineering, 2020.
- [2] S. Bhasin, A. Chattopadhyay, A. Heuser, D. Jap, S. Picek et R. Ranjan, *Mind the Portability : A Warriors Guide through Realistic Profiled Side-channel Analysis*, NDSS Symposium, 2020.
- [3] Y. Ganin et al., *Domain-Adversarial Training of Neural Networks*, Journal of Machine Learning Research, vol. 17, 2016.
- [4] P. Cao et al., *Cross-Device Profiled Side-Channel Attack with Unsupervised Domain Adaptation*, IACR Transactions on Cryptographic Hardware and Embedded Systems (TCHES), 2021.
- [5] G. Zaid, L. Bossuet, A. Habrard et A. Venelli, *Methodology for Efficient CNN Architectures in Profiling Attacks*, TCHES, 2020.
- [6] S. Picek et al., *The Curse of Class Imbalance and Conflicting Metrics with Machine Learning for Side-channel Evaluations*, TCHES, 2019.
- [7] P. Kocher, J. Jaffe et B. Jun, *Differential Power Analysis*, CRYPTO, 1999.
- [8] E. Brier, C. Clavier et F. Olivier, *Correlation Power Analysis with a Leakage Model*, CHES, 2004.
- [9] S. Chari, J. R. Rao et P. Rohatgi, *Template Attacks*, CHES, 2002.
- [10] B. Sun et K. Saenko, *Deep CORAL : Correlation Alignment for Deep Domain Adaptation*, ECCV Workshops, 2016.